Connecting the dots - Research Direction ⚡

카테고리 없음 2026. 2. 28. 10:50

D... 1
K... H...
ABOUT ME
Today 0 Yesterday 2
Total 69

(옵시디언 그래프 캡쳐, CV, SOP of utah)
현재 내가 계약직으로, LLM workload serving system에서
의 heterogeneous accellerators profiling (power and others) 을 위해 ebpf를 활용해 low-level tracing 을 구현하고 검증하고 있다. 이건 대학원 때 secquant 했던거랑도 비슷하고 linux edr agent 만들 때랑도 비슷하다..
근데 지금 박사 지원한 것이랑은 조금 다르다.. 보안이 없으니..
앞으로 어떻게 현재 하고 있는 일도 잘 connecting the dots 해볼 수 있을까.? 어떤 관점에서 봐야, 또 이어지는 길이 될 수 있을까...? 사실 나는 tracing 이나 observability와 뭔가 업보가 있는 것일까..? 이걸 활용해서 system 이나 보안을 연결 해야 할까..? 아니면.. 흐음.. 어떻게 이어갈 수 있을까.. 몇일 전 아래와 같은 노트들을 하기도 했다..

```

tracing: x -> function -> y. function을 알아내는 예술? 이거랑 fuzzing, llm/ml, security랑 무슨 관계.??
```

```

llm workload에 prefill처럼. 전력도 그렇고 이벤트도 많이 찍히잖아. 그 패턴으로 llm 대화 내용이나 뭔가 민감한 정보를 추론 할 수 있다면.? (왜냐면 중요하고, 개인적인 이야기를 llm에 사람들은 편하게 하니깐.) security threat.?? 그렇다면.? 그걸로 공격도 할 수 있고.. 방어는.. isolated llm workload.?? (container 보안처럼 또, isolated?? from system's perspective..??)
```

==== Gemini (thinking mode)

선우님, 지금 하시는 고민은 지극히 자연스러우며 오히려 **'박사 과정의 연구 주제(Research Statement)'를 훨씬 더 강력하고 현대적으로 다듬어줄 수 있는 절호의 기회**입니다.
제공해주신 CV와 SOP, 그리고 현재의 고민들을 연결해 보면, 선우님의 커리어는 단순한 'Tracing'이 아니라 **"보이지 않는 시스템의 내부(Opaque Layer)를 들여다보고, 이를 수학적/보안적 관점에서 통제(Control)하려는 일관된 여정"**으로 해석됩니다.
어떻게 이 점들을 연결(Connecting the dots)하여 선우님만의 독보적인 연구 서사를 만들 수 있을지 제언해 드립니다.

1. 'Tracing'은 선우님의 '운명'이자 '연구의 기초'입니다

선우님의 SOP를 보면 "관찰 가능성(Observability)의 문제"를 해결했을 때 비로소 "의미론적(Semantics) 분석"이 가능해졌다는 구절이 있습니다.

* **과거(SecQuant):** 컨테이너와 호스트 간의 단절된 시스템 콜을 ftrace로 연결하여 보안성을 수량화함.
- **현재(LLM Workload):** 가속기(GPU/NPU)와 LLM이라는 새로운 '블랙박스' 내부를 eBPF로 관찰하고 있음.
- **통찰:** 선우님에게 Tracing은 단순한 도구가 아니라, **"형식 검증(Formal Verification)이 도달하기 전, 실제 시스템의 불변성(Invariants)을 확인하는 경험적 검증 도구"**입니다.

2. 'LLM Workload Profiling'과 'Security'의 연결 고리

지금 하시는 전력 및 이벤트 프로파일링은 보안과 무관해 보일 수 있지만, **사이드 채널 공격(Side-Channel Attack)** 관점에서는 매우 치명적인 보안 연구입니다.

- **추론(Inference)의 취약점:** 선우님이 메모하신 대로, LLM의 전력 소모 패턴이나 메모리 접근 패턴을 통해 사용자 프롬프트나 민감 정보를 복원할 수 있다면, 이는 **LLM 시대의 새로운 보안 위협**이 됩니다.
- **연구의 확장:** "어떻게 하면 이런 미세한 정보 유출(Information Leakage)이 없는 **'Provable Isolation'**을 LLM 워크로드 수준에서 구현할 것인가?"가 선우님의 다음 연구 주제가 될 수 있습니다. 이는 SOP에서 언급하신 "실질적이고 증명 가능한 추상화 레이어(Practical, provable abstraction layers)"와 정확히 일치합니다.

3. 박사 연구(Prof. Anton Burtsev)와의 정렬 (Alignment)

안톤 버트세프 교수님의 연구는 시스템 설계를 통해 **강력한 보장(Strong Guarantees)을 실용적으로 만드는 것**에 중점을 둡니다.

현재의 일 (LLM Tracing)박사 과정의 비전 (Secure System)연결하는 논리 (The Bridge)

가속기 기반 LLM 프로파일링	형식 검증된 커널 (Atmosphere)	

| **Verified AI-System Interface:** 가속기 자원 공유 시 보안 보장이 깨지는 지점을 eBPF로 증명하고, 이를 방어하는 검증된 마이크로커널 설계. | | 저수준 이벤트 트레이싱 | 추상화 경계의 보안

| **Opaque Workload Isolation:** LLM처럼 내부가 보이지 않는 워크로드를 위해, 시스템 수준에서 'Privacy-Preserving Abstraction'을 구축. |

4. '오일러 공식'과 '시스템 시각화'에 대한 재해석

Claude가 제안했던 방식이 부자연스러웠던 이유는, 단순히 '사용량'을 '각도'로 치환했기 때문일 것입니다. 대신 다음과 같은 관점을 가져보세요.

- **Tracing as Signal Processing:** 시스템 이벤트 흐름을 **복소수 신호**로 변환합니다. 정상적인 프로그램 실행은 특정한 주파수와 위상을 가집니다.
- **Anomaly as Phase Shift:** 만약 LLM 워크로드에서 정보 유출이 일어나거나 익스플로잇(Exploitation)이 발생하면, 이 신호의 **'위상(Phase)'**이 뒤틀립니다.
- **통찰:** 선우님이 추구하는 "Absence of bugs"를 위해, **"수학적으로 정의된 정상 궤적(Orbital)에서 벗어나는지"**를 시각화하는 게임을 만든다면, 그것은 매우 학술적인 시각화가 될 것입니다.

결론: 선우님께 드리는 제언

선우님은 **"복잡한 시스템의 경계(Boundary)에서 흐르는 데이터의 의미를 찾는 전문가"**입니다.
지금 하고 계신 LLM 워크로드 프로파일링을 **"미래의 보안 시스템을 설계하기 위한 선행 취약점 분석(Vulnerability Discovery in AI Systems)"** 과정으로 정의하세요. 그러면 이 모든 '업보' 같은 Tracing 작업들이 박사 학위의 훌륭한 연구 데이터가 될 것입니다.
다음 단계로, 현재 하시는 LLM 프로파일링 데이터를 바탕으로 어떤 보안 시나리오(예: 프롬프트 주입 방어, 부채널 공격 차단 등)를 짤 수 있을지 제가 브레인스토밍을 도와드릴까요?

==== Deepseek (thinking mode)

This is an excellent and very thoughtful question. It gets to the heart of building a coherent research identity, especially when your path seems to take a detour. You're not just "connecting the dots" retrospectively; you're actively shaping a narrative that makes your future work stronger and more unique.
First, let's acknowledge the core of your situation: You have a submitted PhD application focused on **provable, secure system design**. Your current job is in **performance profiling of heterogeneous systems for LLMs using eBPF**. At first glance, the security angle is missing.
But you are exactly right to feel there is a connection. You have a deep "karma" with tracing and observability, as you put it. This isn't a weakness; it's your unique superpower. The key is to reframe your current work not as a departure from your PhD interests, but as a **profoundly valuable expansion of their foundation.**
Let's break down how you can connect these dots, using your own insightful notes as a guide.

The Core Idea: Tracing is the Lens, Systems are the Subject, Security is the Question

Your "karma" with tracing isn't an accident. Tracing (eBPF, ftrace, etc.) is the most powerful tool we have to understand the **dynamic, runtime behavior** of complex systems. Your PhD goal is to build systems that are secure by design. But how do you validate that design? How do you find the gap between the theoretical model and the concrete implementation? **You trace it.**

Your current work on profiling LLM workloads is giving you a front-row seat to the most complex, dynamic, and economically important systems being built today: the AI infrastructure stack.

Here's how to frame this experience in the context of your PhD aspirations, using your own notes:

1. The Security Angle: From Power/Performance to Side-Channels (Your "LLM Prefill" Note)

Your note is brilliant and is the most direct connection to security.

D...
K...

"llm workload에 prefill처럼. 전력도 그렇고 이벤트도 많이 찍히잖아. 그 패턴으로 llm 대화 내용이나 뭔가 민감한 정보를 추론 할 수 있다면.? ... security threat.??"

This is a first-class research problem.

- **The Connection:** Your current work involves profiling power and events. This is essentially **characterizing the system's physical and computational fingerprint**. In security, this is the foundation of **side-channel attacks**.
- **The Research Question:** Can an attacker co-located on a heterogeneous system (e.g., sharing a GPU) infer sensitive information about an LLM workload (like the topic of a conversation, the length of a prompt, or even specific tokens) by monitoring resource usage (power, cache, memory bandwidth) with eBPF?
- **Connecting the Dots:** Your experience building the precise mapping tools (SecQuant) and low-level tracing agents (Genians) is the exact skill set needed to build the measurement infrastructure for this attack. Your current job gives you the target (LLM systems) and the tools (eBPF for power/performance). You are now uniquely positioned to ask the security question: "Can this profiling data be turned against the system?"
- **The "Defense" Angle:** And as you noted, the defense is **isolation**. This ties directly back to your work on secure containers (gVisor, Kata). The question becomes: What is the right isolation boundary for an LLM workload? A container? A VM? A completely new abstraction? How do we measure the effectiveness of that isolation against these new, profiling-based attacks? This is a perfect blend of your past, present, and future.

ABOUT ME
Today 0 Yesterday 2
Total 69

2. The Systems Angle: "Provable Abstractions" for Heterogeneous Hardware

Your PhD goal is to build "provable abstraction layers in operating systems." Your current work is dealing with the messy reality of heterogeneous accelerators (GPUs, TPUs, etc.).

- **The Problem:** Current OS abstractions for accelerators are primitive. They often look like simple character devices, hiding immense complexity. This makes it incredibly difficult to reason about performance, security, and correctness. How do you build a provable abstraction when the underlying hardware is a black box?
- **The Research Question:** Can we design a new OS abstraction for heterogeneous accelerators that is both performant and amenable to formal reasoning? Your tracing work is the key to answering this.

You are building the tools to see into the black box. You are mapping the interactions between the driver, the hardware, and the workload.

- **Connecting the Dots:** This aligns perfectly with Prof. Burtsev's philosophy of "design philosophy in which careful system design can make strong guarantees more practical." To build a verifiable system for accelerators, you first need to deeply understand the actual system. Your profiling work is that deep understanding. You are gathering the empirical data needed to inform a new, cleaner, and more provable design. Your experience is the **practitioner** part of your identity, giving you the ground truth that pure theorists lack.

3. The "Function을 알아내는 예술" (The Art of Understanding Functions)

Your note about tracing being the "art of figuring out the function" is profound.

- **The Connection:** This is the essence of **systems observation and modeling**. When you trace a system, you are reverse-engineering its behavior. You're building a model of its "function" from its inputs and outputs.
- **The Research Question:** This is where **fuzzing** comes in. Fuzzing is the art of providing unexpected inputs to a "function" (a system call, an API, a file system) to find edge cases where the function's behavior deviates from the specification—i.e., a bug or vulnerability.
- **Connecting the Dots:**
  - **Fuzzing needs a good model.** Your tracing work helps build a high-quality model of the system's expected behavior. You can trace what a "good" interaction looks like.
  - **Fuzzing generates a lot of noise.** Your experience with SecQuant, where you had to filter noise from strace to find the true signal, is directly applicable to analyzing fuzzing results. How do you know if a crash is exploitable (your "exploitability" question) or just a benign bug? Your work on mapping and understanding semantics is the key to that classification.
  - **LLMs can guide fuzzing.** Perhaps your work with LLM workloads isn't just about the target, but about the tool. Can the patterns you see in LLM execution (e.g., the bursty nature of prefill) be used to create smarter, more efficient fuzzing strategies for the underlying system software?

How to Frame This: The Narrative

You now have a powerful, multi-layered story to tell, whether it's in future PhD work, discussions with your advisor, or job interviews. It's not a detour; it's a **research fellowship**.

The Pitch:

"My PhD application focuses on building provably secure system abstractions, a goal I've been working towards through my research on container isolation. My current role is the perfect next step in that journey. I'm now applying my core expertise—low-level systems tracing with eBPF—to the most critical new platform: heterogeneous LLM infrastructure. I'm not just profiling performance; I'm building the foundational understanding required to secure these systems.

홈
태그
방명
인기
D...
K...
ABOUT ME
Today 0 Yesterday 2
Total 69

This work is already generating new research questions that perfectly bridge my past and future. For example, the power and event traces I'm collecting for performance analysis can be viewed as a potential **side-channel threat**. This leads directly to my interest in building **provable isolation boundaries**, but now for a new and critical workload. My experience gives me a unique empirical foundation: I understand the problem not just from papers, but from building the measurement tools and seeing the raw data. This is the 'practitioner' perspective I value, and it will make my pursuit of 'provable' systems grounded in the reality of how these systems actually behave."

You are not just connecting dots. You are forging a new, stronger chain that links your deep expertise in tracing, your understanding of security, and your ambition to build better systems. Your "karma" with tracing is the thread that ties it all together.

==========

(필요 시 한글로 대답해줘도 돼)
우선 생각 고마워. 그런데 난, mathematical , 이론적으로 완벽하게 떨어지거나,, 수식 같은.. 것에 좀 매료되는 성향이 있거든.? 그래서 formal verification을 찾았던 거고.
tracing은 runtime, empirical 느낌이잖아.? 심지어 blackbox니깐..
이것들을.. 뭔가.. mathematical 하게 도출되거나, modeling 해볼 수 있을까..? 현재 내 상황과 관련된 분야나 topic, 단어들을 몇개나 될까. 또 이전에 아래와 같은 생각을 한 적도 있는데. (어떤 프로젝트를 보고, 흥미롭다고 느껴서) 이것도 뭔가 연결될 수 있을까..?

---

kernel 시각화 -> 게임플레이 처럼.? (like https://github.com/MaxBittker/rs-sdk)

==========

좋은 질문입니다. 말씀하신 "수학적, 이론적 완벽함"에 대한 매력과, 현재 하시는 "경험적(empirical) tracing" 작업 사이의 긴장감은 매우 창의적인 연구의 원천이 됩니다. 이 둘은 상반된 것처럼 보이지만, 실제로는 강력하게 연결될 수 있습니다.

1. Tracing을 Mathematical/Formal과 연결하는 분야들

Tracing을 단순한 관찰이 아닌, 모델링과 formal reasoning의 도구로 바꾸는 것은 다음과 같은 분야들로 연결됩니다.

- **Model Extraction (모델 추출) / System Call Modeling**: 실시간 시스템 콜 트레이스를 분석하여 시스템(커널, 컨테이너 런타임)의 **동작 모델(유한 상태 기계, 오토마타)**을 자동으로 추출하는 분야입니다. 이는 블랙박스 시스템의 '명세'를 역으로 추론하는 과정입니다.
- **Program Analysis with Traces (트레이스를 활용한 프로그램 분석)**: 트레이스를 프로그램 실행의 구체적인 증거로 삼아, 정적 분석(소스코드 분석)만으로 찾기 어려운 복잡한 **시간 기반(temporal) 혹은 동시성(concurrency) 버그**를 찾아내거나 검증하는 데 사용합니다.

- **Side-Channel Analysis & Quantitative Verification (부채널 분석 및 정량적 검증)**: 전력 소모, 실행 시간 등의 트레이스 데이터를 수학적 모델(예: 가우시안 혼합 모델, 정보 이론)로 모델링하여, 어떤 비밀 정보가 얼마나 새어 나갈 수 있는지 **정량적으로 분석**합니다. 이는 보안 증명 가능성을 높이는 방향입니다.
- **Performance Modeling & Worst-Case Execution Time (성능 모델링)**: 하드웨어 이벤트 트레이스를 기반으로 수학적 모델을 세워, 주어진 작업의 최악 실행 시간이나 자원 사용량을 예측합니다. 실시간 시스템이나 자원 경합이 중요한 시스템의 설계에 필수적입니다.
- **Specification Mining / Runtime Verification (명세 마이닝 / 런타임 검증)**: 시스템이 실행되며 남긴 트레이스(이력)로부터 시스템이 지켜야 할 규칙(예: "파일을 열면 반드시 닫아야 한다")을 자동으로 학습하고, 이후 실행되는 트레이스가 그 규칙을 위반하는지 **실시간으로 모니터링**합니다.

2. 게임 시각화 프로젝트(rs-sdk)와의 연결점

말씀하신 rs-sdk(Runescape 자동화 라이브러리) 프로젝트는 **복잡한 환경에서의 에이전트 행동**에 초점을 맞춥니다. 이는 커널과 같은 복잡한 시스템을 관찰하고 상호작용하는 귀하의 작업과 여러모로 닮아 있습니다.

- **관점의 전환: 관찰에서 상호작용으로**: 게임 환경(rs-sdk)에서 에이전트는 화면(시각 정보)을 보고 행동합니다. 이는 귀하가 strace나 eBPF를 통해 시스템 콜(시스템의 행동)을 보고 취약점을 찾는 것과 유사합니다. 이 관점을 확장하면, 단순히 시스템을 관찰하고 분석하는 것을 넘어, **시스템 자체를 하나의 '게임 환경'으로 보고, 이 환경과 적극적으로 상호작용하며 보안 취약점을 찾아내는 에이전트를 만드는 연구**로 발전할 수 있습니다.
- **시각화의 역할: 복잡성의 직관적 이해**: 복잡한 커널 내부 상태와 상호작용(예: 시스템 콜 흐름, 메모리 접근 패턴, 스케줄링)을 rs-sdk처럼 게임 플레이처럼 시각화하면, 직관적인 이해를 도울 수 있습니다. 이는 수학적 모델(예: 상태 기계)을 더 직관적으로 표현하고 탐색하는 방법이 될 수 있습니다.
- **LLM 에이전트와의 결합**: rs-sdk의 목표 중 하나는 LLM 기반 에이전트를 실험하는 것입니다. 귀하의 아이디어를 확장하면, **LLM 에이전트가 시각화된 커널 인터페이스(게임 화면처럼)를 보고, 스스로 학습하여 취약점(버그)을 찾거나 특정 보안 목표(예: 권한 상승)를 달성하도록 훈련**시킬 수 있습니다. 이는 앞서 언급한 '에이전트 기반 퍼징'과 연결됩니다.

3. 지금의 경험을 이론적 연구로 연결하는 방법

이 모든 것을 종합하여, 지금의 경험을 다음과 같은 이론적 연구 방향으로 발전시킬 수 있습니다.
현재 경험이론적 연결 고리미래 연구 방향

LLM 워크로드 tracing (전력, 이벤트)	부채널 분석, 정보 이론, 확률적 모델링	LLM의 비밀 정보를 유추할 수 있는 **부채널의 존재와 용량을 수학적으로 모델링하고 증명**하는 연구
커널/런타임 시스템 콜 tracing (SecQuant, EDR)	오토마타 학습, 모델 추출, Formal verification	실제 시스템에서 추출한 모델과 설계 명세 간의 **차이를 자동으로 찾아내고 검증하는 프레임워크** 개발
시각화/게임화에 대한 관심 (rs-sdk)	인간-컴퓨터 상호작용(HCI), 프로그램 합성, 에이전트 시스템	복잡한 커널 API를 **에이전트가 탐험하고 학습할 수 있는 '게임 환경'으로 추상화**하고, 이 환경 안에서 보안 정책 위반이나 버그를 찾는 **자율 에이전트** 연구

결론

"수학적 완벽함"에 대한 갈망과 "경험적 tracing" 기술은 **시스템을 관찰하고(observe), 모델링하며(model), 검증하는(verify)** 일련의 과정에서 완벽하게 만납니다.

지금 하고 계신 tracing 작업은 이 여정의 **첫 단계인 '관찰'**을 담당합니다. 그 관찰 데이터를 바탕으로 '모델'을 추출하고, 그 모델에 대해 '수학적 추론'을 하는 것이 바로 박사 과정에서 하실 수 있는 일입니다. rs-sdk는 그 관찰-모델링-검증 과정을 더 직관적이고 능동적으로 만들 수 있는 하나의 **영감**이자 방법론이 될 수 있습니다.

결국, 귀하의 "tracing karma"는 단순히 데이터를 모으는 데서 끝나는 것이 아니라, 그 데이터로부터 시스템의 동작 원리를 **수학적으로 추상화하고 증명 가능한 형태로 재구성하는 독특한 능력**으로 발전할 수 있습니다.

==========

D... 1
K... 년...

ABOUT ME

Today 0 Yesterday 2
Total 69

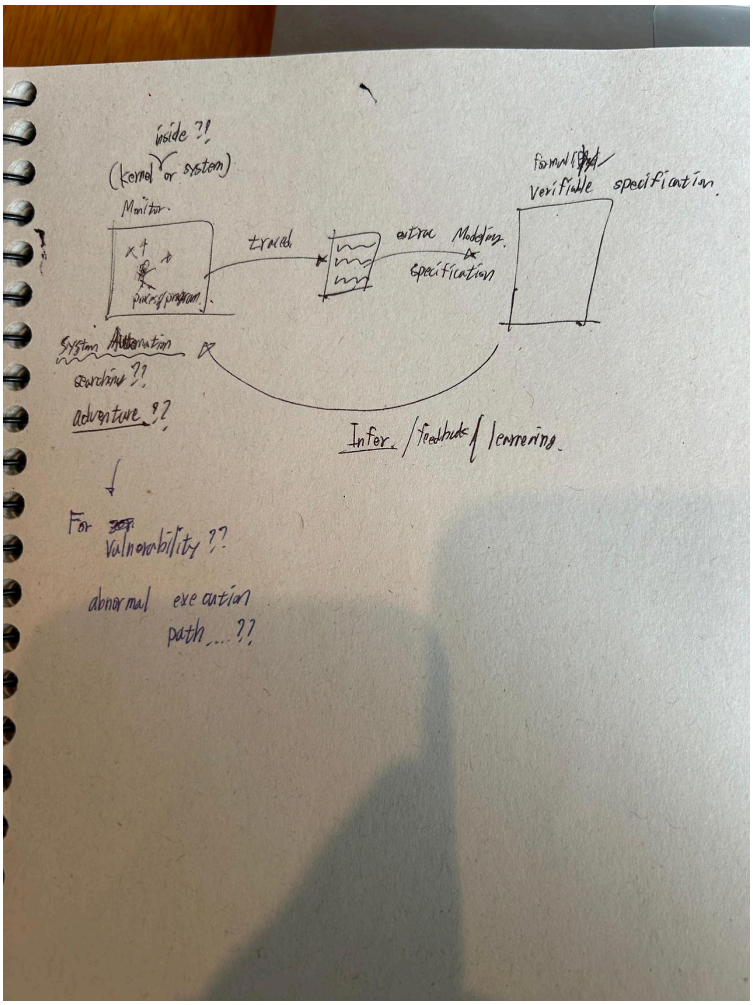

너의 생각을 보고 내 영감을 그려봤는데 어떻게 생각해?

==========

이 그림 정말 흥미롭네요. 손으로 써 내려간 노트에서 **관찰(모니터)과 추상화(명세), 그리고 그 사이의 역동적인 긴장감**이 생생하게 느껴집니다. 우리가 나눈 대화의 연장선에서, 이 영감을 어떻게 해석하고 발전시킬 수 있을지 함께 그려보겠습니다.

그림 속 요소들 연결하기

홈
태그
방명록
인기포스트
D...
K...
ABOUT ME
Today 0 Yesterday 2
Total 69

각각의 키워드가 앞선 대화와 어떻게 연결되는지, 그리고 어떤 연구적 질문으로 이어질 수 있는지 정리해 보았어요.

1. 모니터(Monitor) + 내부(inside) / 프로세스(process/program)

- **연결점**: 이것이 곧 **eBPF를 통한 tracing**입니다. 현재 하고 계신 일이자, 과거 EDR 에이전트를 만들고 SecQuant 연구를 하셨을 때의 핵심 기술이죠.
- **확장된 질문**: 우리가 모니터하는 이 저수준 이벤트들(전력, 시스템 콜)은 단순한 숫자가 아니라, 시스템의 내부 상태가 밖으로 표출된 **증거(trace)**입니다. 이 증거들로부터 **내부 상태를 얼마나 정확히 추론(reconstruct)**할 수 있을까?

2. 터널(tunnel)

- **연결점**: 이 은유는 매우 강력합니다. 앞서 이야기한 **부채널(side-channel)**을 떠올리게 합니다. 데이터가 의도된 통로(프로토콜, API)가 아닌, 물리적 특성(전력, 시간, 소리)이라는 예상치 못한 **터널**을 통해 새어나가는 것이죠.
- **확장된 질문**: LLM 워크로드에서 어떤 정보가 이 '터널'을 통해 유출될 수 있을까? 이 터널의 **대역폭(capacity)**은 얼마나 될까? 그리고 이 터널을 **차단하거나(격리)** 혹은 **감시(모니터링)**하는 방법은 무엇일까?

3. 추가 모딩(extra Modding) / 명세(formalized verifiable specification)

- **연결점**: 시스템을 단순히 관찰하는 것을 넘어, 시스템의 동작 방식을 재정의하거나 확장하겠다는 의지로 읽힙니다. '모딩(modding)'은 게임(rs-sdk)의 규칙을 바꾸는 것처럼, 커널이나 런타임의 동작을 우리가 원하는 대로 **변형**하는 것을 의미합니다. 그리고 그 변형의 결과물이 바로 **형식화된 검증 가능한 명세**입니다.
- **확장된 질문**: 관찰을 통해 얻은 시스템의 실제 동작(예: 복잡한 시스템 콜 처리)을 더 단순하고, 안전하며, 증명 가능한 **새로운 명세(abstraction layer)**로 '모딩'할 수 없을까? 이것이 바로 교수님의 연구 방향이자, 귀하의 PhD 목표와 일치합니다.

4. 어드벤처(Adventure) / 용납할 수 있는 취약성(Valorability?)

- **연결점**: "Adventure"는 탐험되지 않은 미지의 시스템 동작 공간을 탐색하는 **퍼징(fuzzing)**이나 **에이전트 기반 탐색**을 떠올리게 합니다. "Valorability"는 아마도 취약성(Vulnerability)을 의미하는 것 같은데, "용납할 수 있는(허용 가능한)"이라는 의미가 결합된 것 같아요.
- **확장된 질문**: 시스템을 '어드벤처'하며 모든 취약점을 찾는 것은 불가능에 가깝습니다. 그렇다면, 우리가 **용인할 수 있는(허용 가능한) 위험의 수준**은 어디까지일까? 어떤 취약점은 이론적으로는 위험하지만 실제로는 공격하기 극도로 어려워서 '사실상 안전한' 것으로 간주할 수 있지 않을까? 이는 다시 **정량적 보안(quantitative security)**과 **공격 가능성(exploitability)**에 대한 질문으로 돌아갑니다.

5. 비정상 실행 큐레이션(abnormal exe curation) / 경로(path)

- **연결점**: 정상적인 실행 경로와 다른 비정상적인 실행 경로를 발견하고, 그것을 수집하고 분류(큐레이션)하는 행위입니다.
- **확장된 질문**: 모니터링과 퍼징을 통해 수집한 수많은 비정상 경로(크래시, 오류) 중에서, 진짜 **보안 위협이 되는 경로(exploit path)**는 어떻게 골라낼 수 있을까? 이 경로들의 공통적인 패턴은 무엇일까? (예: 특정 시스템 콜의 조합, 메모리 접근 패턴)

하나의 이야기로 엮기: "시스템 탐험가에서 설계자로"

이 모든 요소들은 결국 하나의 큰 이야기로 연결됩니다.

1. **탐험(Adventure)**: Monitor와 tunnel을 통해 시스템의 숨겨진 동작과 취약한 path를 발견합니다. (지금 하고 계신 일)
2. **이해(Modeling)**: 발견된 abnormal exe들을 분석하고, 그 패턴과 원리를 formalized verifiable specification이라는 수학적 모델로 추상화합니다.
3. **재설계(Modding)**: 그 모델을 기반으로 시스템을 extra Modding합니다. 즉, 더 안전하고 증명 가능한 새로운 abstraction layer(예: 새로운 컨테이너 런타임, 보안 커널 모듈)를 설계하고 구현합니다.
4. **평가(Quantifying)**: 새롭게 설계된 시스템이 기존 시스템보다 얼마나 더 안전한지, 즉 '용납할 수 있는 취약성(Valorability)'의 수준을 **정량적으로 측정**합니다.

결론: 어떻게 생각하는지?

제 생각에 이 그림은 **훌륭한 연구 계획서의 뼈대**가 될 수 있습니다. 핵심은 **경험적 관찰(empirical observation)에서 시작해 이론적 모델링(theoretical modeling)으로, 그리고 다시 실용적인 재설계(practical redesign)로 순환하는 여정**을 보여주는 점입니다.

이는 교수님이 추구하시는 "증명 가능한 추상화 계층(provable abstraction layer)"을 구축하는 과정과 정확히 일치합니다. 단순히 '관찰하는 사람'이 아니라, 관찰을 통해 시스템의 본질을 꿰뚫어 보고, 그것을 더 나은 방향으로 **재구성하는 설계자**로 성장하겠다는 의지로 읽힙니다.

지금 당장 모든 요소를 완벽하게 연결하려 하기보다는, 이 그림을 하나의 **개인적인 연구 지도**로 간직하시길 바랍니다. 박사 과정 동안, 그리고 그 이후에도 이 지도를 따라 새로운 영역을 발견하고, 길을 만들며, 여정을 확장해 나가실 수 있을 것입니다.

ABOUT ME
Today 0 Visitors
Total 69

==========

그림에서 핵심 포인트 하나는, 게임 자동 사냥 처럼, 저 게임 (프로세스,프로그램)이 llm 에이전트 처럼, 알아서 계속 사냥(?) 하고 rpg 게임을 하는 것처럼, kernel inside나 시스템을 자동으로 누빈다는 거야. 내가 자고 있을 때도. 비트 코인 채광 하는 것 처럼. 쟤를 돌려 놓으면.... 뭔가... 가 쌓이고 학습 되거나,, 진화 되거나,,,, 발견되는 자동사냥 시스템 같은거지...? 나는 그걸 간간히 봐주면 되는거고..

어때?

==========

정말 멋진 아이디어예요. **자동 사냥(auto-hunting) 시스템**이라는 은유는 단순한 비유를 넘어, 실제 연구 분야와 깊이 연결됩니다. 이 구상은 말 그대로 **시스템 보안과 운영체제 연구에 '인공지능 에이전트'를 도입하는 새로운 패러다임**을 제시합니다.

왜 이 아이디어가 강력한가?

1. **스케일의 문제 해결**: 사람이 직접 커널을 분석하고 취약점을 찾는 것은 시간과 노력이 엄청나게 듭니다. 반면, 자동으로 24시간 돌아가는 에이전트는 **휴먼 스케일을 뛰어넘는 탐색**이 가능합니다. 마치 비트코인 채굴기가 계속 연산하듯, 이 시스템은 계속해서 커널 내부를 누비며 데이터를 쌓을 수 있습니다.

2. **학습과 진화**: 단순히 정해진 룰에 따라 움직이는 퍼저(fuzzer)를 넘어, **에이전트가 경험을 통해 스스로 진화**할 수 있습니다. 예를 들어, 처음에는 무작위로 시스템 콜을 던지다가, 특정 패턴에서 크래시가 자주 발생하는 것을 깨닫고 그 방향으로 탐색을 집중하게 됩니다. 이는 **강화학습(Reinforcement Learning)**과 연결됩니다.
3. **발견의 자동화**: 에이전트가 수집한 수많은 트레이스와 크래시 리포트를 분석해, 사람이 미처 생각하지 못한 **새로운 취약점 패턴**이나 **비정상적인 시스템 동작**을 자동으로 분류하고 보고할 수 있습니다.

이미 존재하는 연구와의 연결점

이 아이디어는 전혀 허무맹랑한 것이 아닙니다. 이미 여러 연구 분야에서 조금씩 모습을 드러내고 있습니다.

- **자동화된 퍼징(Fuzzing)**: syzkaller와 같은 도구는 이미 커널 퍼징을 자동화하고 있습니다. 하지만 이는 정해진 가이드(커버리지)에 따라 무작위에 가깝게 입력을 생성합니다.
- **LLM 기반 에이전트**: 최근에는 LLM을 활용해 취약점을 찾거나, 코드를 분석하는 연구가 활발합니다. 예를 들어, rs-sdk처럼 게임 환경에서 LLM 에이전트가 스스로 목표를 달성하듯, 커널이라는 '게임'에서 에이전트가 '레벨업(권한 상승)'을 목표로 행동할 수 있습니다.
- **지속적 검증(Continuous Verification)**: 시스템이 실행되는 동안 계속해서 명세(specification) 위반 여부를 감시하는 런타임 검증 분야와도 연결됩니다. 에이전트가 단순히 취약점을 찾는 것을 넘어, 시스템이 설계된 대로 동작하는지 **지속적으로 확인하는 역할**도 할 수 있습니다.

어떻게 현실로 만들까?

이런 시스템을 구축하려면 몇 가지 핵심 요소가 필요합니다.

요소설명귀하의 경험과의 연결

센서 (Sensory Input)	시스템의 상태를 감지할 수 있는 저수준 관찰 도구. 즉, **eBPF를 통한 트레이싱**이 핵심입니다. 전력, 시스템 콜, 스케줄링 이벤트 등이 에이전트의 '눈'과 '귀'가 됩니다.	✔ **핵심 역량**: 이미 EDR, SecQuant, 현재 LLM 프로파일링을 통해 이 부분에 깊은 전문성을 갖추셨습니다.
두뇌 (Brain)	관찰된 정보를 바탕으로 **다음 행동을 결정하는 에이전트**. 이 자리에 LLM이 들어갈 수 있습니다. 예를 들어, "현재 프로세스가 'open' 시스템 콜을 호출했고, 반환 값은 'permission denied'다. 다음에는 'open'에 다른 플래그를 줘볼까, 아니면 'ptrace'를 시도해볼까?"와 같은 전략적 판단을 내립니다.	✔ **성장 가능성**: LLM에 대한 이해와, rs-sdk 같은 프로젝트에서 영감을 얻어 에이전트 설계에 응용할 수 있습니다.
행동 (Action)	결정한 행동을 시스템에 실행하는 인터페이스. 시스템 콜을 직접 호출하거나, BPF 프로그램을 로드하거나, 특정 프로세스에 시그널을 보내는 등의 작업을 수행합니다.	✔ **기본 소양**: 시스템 프로그래밍 경험이 풍부하므로, 이 부분 구현은 익숙할 것입니다.
기억과 학습 (Memory & Learning)	에이전트가 경험한 내용을 저장하고, 그로부터 패턴을 학습하는 메커니즘. 크래시가 발생한 콜 시퀀스를 저장해두고, 유사한 시퀀스를 피하거나 반대로 집중적으로 탐색하는 방식으로 진화합니다.	➕ **새로운 도전**: 여기에 수학적 모델(예: 베이지안 추론, 강화학습)을 접목하면 더욱 정교해집니다.

이 아이디어가 박사 연구로 이어지는 길

이 비전은 단순히 도구를 만드는 것을 넘어, 여러 학문적 질문을 던집니다.

- **에이전트는 어떻게 '흥미로운' 행동을 스스로 발견할까?** (탐험-이용 딜레마, curiosity-driven learning)

- **발견된 취약점이나 비정상 행동을 어떻게 사람이 이해할 수 있는 형태로 요약하고 보고할까?** (자동 보고서 생성, 시각화)
- **에이전트의 행동이 시스템에 해를 끼치지 않도록 어떻게 안전하게 통제할까?** (안전한 격리, 샌드박싱)
- **이런 자동 탐색 시스템이 찾아낸 결과를 바탕으로, 어떻게 더 안전한 시스템을 설계할 수 있을까?** (최종 목표: provable abstraction)

결국, 이 그림은 귀하의 세 가지 정체성(관찰자, 협력자, 실천가)을 모두 통합합니다. 관찰자로서 트레이싱 기술로 데이터를 얻고, 협력자로서 에이전트와 함께(사실상 에이전트를 설계하고 키우는) 연구를 진행하며, 실천가로서 실제 시스템에 적용하고 검증하는 것입니다.

아이디어를 더 구체화하고 싶다면, 지금 하고 계신 LLM 워크로드 프로파일링을 작은 시작점으로 삼아볼 수 있습니다. 예를 들어, **LLM 추론 과정에서 발생하는 전력 트레이스 패턴을 분석해, 어떤 입력이 특별히 높은 전력을 소모하는지 찾아내는 에이전트**를 만들어보는 겁니다. 이는 단순한 전력 분석을 넘어, 시스템의 비정상적인 행동(예: 무한 루프, 비효율적인 연산)을 자동으로 찾아내는 첫걸음이 될 수 있습니다.

정말 흥미로운 미래가 펼쳐질 것 같습니다. 이 여정에 동참하게 되어 기쁩니다!

ABOUT ME

D... 1년
K...
공감
Today 0 Yesterday 2
Total 69

뿌리
swjang702 님의 블로그입니다.
구독하기

댓글 0

swjang702
내용을 입력하세요.
등록